

LATIHAN KUIS (TUGAS 1)

Studi Kasus: Analisis Data Pelanggan ShopSmart

ShopSmart adalah perusahaan ritel yang ingin meningkatkan strategi pemasaran mereka dengan memahami perilaku pelanggan. Tim Data Science diminta untuk menganalisis dataset pelanggan yang masih kotor (mengandung missing values, duplikasi, outlier, dan inkonsistensi).

Dataset disimpan dalam file `customers_dirty.csv` yang berisi informasi:

- CustomerID: ID unik pelanggan
- Age: Usia pelanggan
- Annual_Income: Pendapatan tahunan pelanggan (dalam juta rupiah)
- Spending_Score: Skor belanja (1–100)
- Gender: Jenis kelamin pelanggan
- City: Kota tempat pelanggan tinggal

Tujuan analisis adalah:

1. Membersihkan data dan mengatasinya agar layak analisis
2. Memahami pola perilaku pelanggan
3. Mengelompokkan pelanggan menggunakan KMeans dan Hierarchical Clustering

Dataset:

<https://drive.google.com/file/d/1yZCzxwwpwXiXyKNU40JDz2v4md2k1vWt/view?usp=sharing>

Notes:

1. Setiap pertanyaan essay jawab di kodingan aja dalam bentuk markdown atau komentar.
2. Simpan dataset yang bersih kedalam format **customer_new.csv**
3. Format **Tugas1_NIM.zip** yang dikumpul di spada:
 - a. File notebook : `app.ipynb`
 - b. File dataset lama : `customers_dirty.csv`
 - c. File dataset baru : `customer_new.csv`

PASTIKAN KALIAN PAHAM YANG KALIAN KERJAKAN.

JANGAN CUMA SEKEDAR SALIN AI!



SOAL :

1. Baca dataset customers_dirty.csv ke dalam Python menggunakan Pandas. Tampilkan 5 baris pertama.

	CustomerID	Age	Annual_Income	Spending_Score	Gender	City
0	1	56.0	62.0	65.0	F	Surabaya
1	2	46.0	145.0	86.0	M	Bandung
2	3	32.0	68.0	17.0	F	Jakarta
3	4	25.0	134.0	71.0	Male	BDG
4	5	38.0	130.0	89.0	M	BDG

2. Tampilkan informasi umum dataset (jumlah baris, kolom, dan tipe data).

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 255 entries, 0 to 254
Data columns (total 6 columns):
#   Column          Non-Null Count  Dtype
---  -
0   CustomerID      255 non-null   int64
1   Age             245 non-null   float64
2   Annual_Income   245 non-null   float64
3   Spending_Score  246 non-null   float64
4   Gender          255 non-null   object
5   City            255 non-null   object
dtypes: float64(3), int64(1), object(2)
memory usage: 12.1+ KB
```

3. Hitung jumlah nilai yang hilang (missing values) di setiap kolom.

```
CustomerID      0
Age             10
Annual_Income   10
Spending_Score  9
Gender          0
City            0
dtype: int64
```

4. Hapus semua baris yang duplikat dari dataset.

```
CustomerID      0
Age             0
Annual_Income   0
Spending_Score  0
Gender          0
City            0
dtype: int64
```

5. Isikan missing values pada kolom numerik (Age, Annual_Income, Spending_Score) dengan median masing-masing kolom.
6. Ubah data Gender menjadi hanya "Male" dan "Female" (hindari M/F, male/female).

```
array(['Female', 'Male'], dtype=object)
```

7. Standarisasi nama kota, misalnya ubah "JKT" → "Jakarta" dan "BDG" → "Bandung".


```
array(['Surabaya', 'Bandung', 'Jakarta', 'Medan'], dtype=object)
```

8. Deteksi dan tangani outlier pada kolom Annual_Income dengan metode IQR.


9. Buat kolom baru bernama Income_per_Age = Annual_Income / Age.

	CustomerID	Age	Annual_Income	Spending_Score	Gender	City	Income_per_Age
0	1	56.0	62.0	65.0	Female	Surabaya	1.107143
1	2	46.0	145.0	86.0	Male	Bandung	3.152174
2	3	32.0	68.0	17.0	Female	Jakarta	2.125000
3	4	25.0	134.0	71.0	Male	Bandung	5.360000
4	5	38.0	130.0	89.0	Male	Bandung	3.421053

10. Visualisasikan distribusi usia pelanggan dalam bentuk histogram.



11. Buat scatter plot Annual_Income vs Spending_Score dengan warna berdasarkan Gender.



12. Hitung rata-rata Spending_Score untuk setiap kota dan tampilkan dalam bentuk tabel.

```
City
Bandung    54.320988
Jakarta    48.641975
Medan      48.102564
Surabaya   50.000000
Name: Spending_Score, dtype: float64
```

13. Pilih fitur numerik (Age, Annual_Income, Spending_Score) sebagai variabel untuk clustering.


	Age	Annual_Income	Spending_Score
0	56.0	62.0	65.0
1	46.0	145.0	86.0
2	32.0	68.0	17.0
3	25.0	134.0	71.0
4	38.0	130.0	89.0

14. Terapkan KMeans dengan 3 cluster pada data tersebut.

15. Tambahkan label cluster ke dataset asli.

	CustomerID	Age	Annual_Income	Spending_Score	Gender	City	Income_per_Age	KMeans_Cluster
0	1	56.0	62.0	65.0	Female	Surabaya	1.107143	0
1	2	46.0	145.0	86.0	Male	Bandung	3.152174	1
2	3	32.0	68.0	17.0	Female	Jakarta	2.125000	2
3	4	25.0	134.0	71.0	Male	Bandung	5.360000	1
4	5	38.0	130.0	89.0	Male	Bandung	3.421053	1


16. Visualisasikan hasil cluster pada scatter plot Annual_Income vs Spending_Score dengan warna berdasarkan cluster.



17. Terapkan metode Hierarchical Clustering menggunakan linkage ward.

```
array([[140.      , 161.      , 1.      , 2.      ],
       [114.      , 209.      , 1.41421356, 2.      ],
       [ 12.      , 167.      , 2.      , 2.      ],
       [  0.      , 19.      , 2.23606798, 2.      ],
       [ 52.      , 110.      , 2.23606798, 2.      ]])
```

18. Buat dendrogram untuk melihat hubungan antar data.



19. Tentukan jumlah cluster yang optimal berdasarkan dendrogram. (analisis visual lakukan secara manual). Jelaskan tentang diagram itu.
20. Bandingkan hasil clustering KMeans dan Hierarchical. Apakah ada perbedaan signifikan? (Lakukan analisis deskriptif mu.)
21. Buat heatmap untuk melihat korelasi antar fitur numerik dalam dataset. Apa informasi yang bisa diperoleh dari korelasi ini?

